NMF seminar: prijedlog tema i način rada

Matrične i tenzorske metode u analizi podataka · Lovro, za Saru i Mislava · 1. studenoga 2026.

Moramo detaljno obraditi nenegativnu matričnu faktorizaciju, implementirati je u Pythonu i primijeniti na nov konkretan problem. Ovdje su četiri moguće izvedbe. Svaka ima drugi problem i drugi algoritam iz literature, pa izbor teme određuje i matematiku koju ćemo braniti. **Predlažem temu 1, a temu 2 kao rezervu.** Ništa još nije odlučeno.

Podaci i licence provjereni su 1. studenoga 2026., ali nijedna metoda još nije pokrenuta, pa su očekivani rezultati zasad samo pretpostavke. Svuda koristimo model $A \approx WH$, gdje je $A \in \mathbb{R}^{m\times n}_{\geq 0}$, $W \in \mathbb{R}^{m\times r}_{\geq 0}$ i $H \in \mathbb{R}^{r\times n}_{\geq 0}$.

1. Četiri teme

Tema 1: Kartiranje močvare Kopački rit iz satelitskih snimaka

Pitanje je može li se bez ručno označenih podataka iz snimaka Sentinel-2 odvojiti vodu, močvarnu vegetaciju, šumu i polja te izmjeriti kako se površina pod vodom mijenja kroz godinu. Stupci matrice A su pikseli, a retci spektralni kanali na nekoliko datuma. Spektar piksela smatramo kombinacijom spektara materijala, što je linearni model miješanja iz Gillisa (odj. 2.3): stupci W su spektri materijala, a stupci H njihovi udjeli. Najčišće piksele tražimo algoritmom SPA (Gillis, odj. 3.2.2) i njima pokrećemo faktorizaciju ranga 2. Svaki čvor dijelimo pomoću ANLS-a sa zatvorenom formulom (L6, odj. 3), pa nastaje stablo materijala. Završne karte udjela dobivamo nenegativnim najmanjim kvadratima uz fiksirani W. Rezultat uspoređujemo s k-means i pragom indeksa NDWI, a slaganje mjerimo s kartom ESA WorldCover 2021, koja je i sama nesavršena referenca (ukupna točnost 76,7 %). Jedna pločica (34TCR) pokriva cijelo područje i za 2025. ima 39 snimaka s manje od 30 % oblaka na razini pločice. Rizici su oblaci, malo proljetnih snimaka i pravilo dijeljenja mNDCG iz L6, koje je smišljeno za riječi pa će ga možda trebati zamijeniti.

Tema 2: Automatsko prepisivanje gitare u note

Pitanje je može li NMF iz snimke akustične gitare prepoznati koje tonove glazbenik svira i kada. Stupci A su vremenski okviri, a retci frekvencijski binovi amplitudnog spektrograma. Spektar u nekom trenutku približno je zbroj spektara tonova koji tada zvone, pa su stupci W predlošci tonova, a retci H njihove aktivacije kroz vrijeme. Koristimo generaliziranu KL divergenciju i multiplikativna ažuriranja iz L3, gdje je cijeli dokaz nerasta funkcije cilja pomoću pomoćne funkcije (teorem 2, odj. 6). L3 tvrdi i konvergenciju prema lokalnom minimumu, ali L4 (odj. 3.1) pokazuje da taj dokaz daje samo nerast, pa u seminaru razdvajamo što je dokazano, a što nije. Predloške učimo na pet gitarista, a transkripciju provjeravamo na šestom, i to ponavljamo za svakoga. Uz fiksirani W problem po H je konveksan, pa je obrada nove snimke brza i lako objašnjiva. Skup GuitarSet (CC BY 4.0) ima 360 snimaka šest gitarista i 62.476 označenih tonova, a dovoljna je arhiva od 657 MB. Rezultat mjerimo standardnim F1 na razini nota i uspoređujemo ga s Frobeniusovom funkcijom cilja i jednostavnim odabirom spektralnih vrhova. Rizik je što isti ton zvuči različito na različitim žicama, a akordi se preklapaju, pa rezultat može biti skroman. Dodatno moramo objasniti kratkotrajnu Fourierovu transformaciju.

Tema 3: Predviđanje šahovskog repertoara

Pitanje je može li se iz malog broja partija predvidjeti koja će otvaranja šahist igrati, što pomaže u pripremi protiv protivnika. Stupci A su igrači, a retci otvaranja odvojeno za bijele i crne figure, što je izravna analogija matrice riječi i dokumenata iz L5. Zato koristimo težine TF-IDF i HierNMF2 iz L6, pa stablo može otkriti repertoarske stilove igrača. Težine novog igrača računamo nenegativnim najmanjim kvadratima uz fiksirani W, što bi trebalo raditi i uz malo partija. Partije dijelimo vremenski: prvi dio mjeseca služi za učenje, a drugi za provjeru predviđanja. Uspoređujemo se s popularnošću otvaranja i igračevim vlastitim histogramom, a stablo s ECO klasifikacijom otvaranja. Baza Lichess je pod licencom CC0, a za srpanj 2014. ima 1.048.440 partija, 2.619 naziva otvaranja i 5.481 igrača s barem 100 partija. Ta datoteka ima oko 200 MB, pa je obrada izvediva na običnom računalu. Rizik je što otvaranje ovisi i o protivniku, pa značajke treba pažljivo definirati. NMF možda neće pobijediti vlastiti histogram, što bi bio legitiman negativan rezultat.

Tema 4: Razdvajanje bojila na histološkim slikama

Preparati tkiva bojani hematoksilinom i eozinom razlikuju se u boji među laboratorijima i skenerima, što smeta automatskoj analizi. Pitanje je može li NMF ranga 2 razdvojiti ta dva bojila i time ujednačiti boje slika.

Nakon Beer-Lambertove transformacije u optičku gustoću piksel je približno nenegativna kombinacija boja dvaju bojila, pa rang određuje fizika, a ne naš izbor. Stupci A su pikseli jedne slike, retci tri RGB kanala, stupci W boje bojila, a retci H njihove gustoće. Budući da A ima samo tri retka, nejedinstvenost NMF-a možemo nacrtati kao konus u trodimenzionalnom prostoru. Prema Vahadaneu i suradnicima dodajemo kaznu ℓ_1 na H, a problem rješavamo HALS-om s mekim pragom (Gillis, odj. 3.1.5). Metodu uspoređujemo s Macenkovom, a korist mjerimo jednostavnim klasifikatorom tkiva provjerenim na drugim pacijentima. Skup NCT-CRC-HE-100K (CC BY 4.0) ima 100.000 nenormaliziranih isječaka devet vrsta tkiva i 7.180 isječaka od 50 drugih pacijenata. Puna arhiva ima 11,7 GB, ali dovoljan je uzorak pojedinačnih slika. Rizici su potrebno medicinsko predznanje, moguća prethodna normalizacija validacijskih slika i to što nazivi datoteka ne otkrivaju s kojeg preparata isječak potječe.

2. Usporedba

Tema	Funkcija cilja i algoritam	Veza s literaturom	Vrednovanje	Licenca podataka
1. Kopački rit	Frobeniusova; SPA, rang-2 ANLS, stablo	L1 (2.3, 3.1.4, 3.2.2), L6	Slaganje s WorldCoverom, k-means, NDWI	Sentinel otvoren; WorldCover CC BY 4.0
2. Gitara	KL; multiplikativna ažuriranja	L3 (teorem 2), L1 (3.1.2), L4 (3.1)	F1 na notama, provjera na novom gitaristu	CC BY 4.0
3. Šah	Frobeniusova; HierNMF2 na TF-IDF	L5, L6	Predviđanje na kasnijim partijama	CC0
4. Histologija	Frobeniusova s ℓ_1; HALS	L1 (3.1.5), Vahadane i sur.	Usporedba s Macenkom, klasifikator tkiva	CC BY 4.0

Preporuka. Tema 1 najviše pokriva glavni obvezni izvor: model miješanja, ANLS i SPA s dokazom, a stablo dolazi iz L6. Daje i karte koje se dobro prikazuju, ali traži najviše rada s pripremom podataka. Tema 2 ima najčišći dokaz i najjasniju mjeru uspjeha, tema 3 najbliža je radovima o dokumentima, a tema 4 ima najzorniju geometriju, ali traži medicinski kontekst.

3. Predložena metodologija rada: niti

Posao ne dijelimo na teoriju, kod i primjenu. Dijelimo ga na tri isprepletene niti, a svaka ide od matematike preko koda i podataka do rezultata te svog dijela seminara i prezentacije. Metoda je ista za svaku temu.

Nit	Što obuhvaća	Završava
1. Od podataka do prve faktorizacije	Što znači A i zašto je nenegativna, funkcija cilja, uvjeti optimalnosti, nejedinstvenost, izvod ažuriranja, prvi kod i mali primjer koji se može provjeriti ručno	Prvom faktorizacijom na stvarnim podacima i tumačenjem faktora
2. Od faktorizacije do strukture	Izbor ranga ili stabla, inicijalizacija, zaustavljanje, što je o konvergenciji stvarno dokazano, stabilnost kroz sjemena, usporedba s referentnom metodom	Stabilnom strukturom u podacima i usporedbom
3. Od strukture do odgovora	Pretvaranje faktora u odgovor, vrednovanje, nesigurnost, neuspjesi i ograničenja, ponovljivost pokretanja	Odgovorom na pitanje i završnim slikama

Primjer za temu 1: nit 1 završava prvom podjelom scene na vodu i kopno, nit 2 stablom materijala, a nit 3 kartama udjela i krivuljom vode kroz godinu.

Kako radimo:

- Svaka nit ima nositelja, a ne vlasnika. Nositelj prati nit, a niti možemo mijenjati usput.
- AI alat piše kod i prve nacrte, što je na seminaru dopušteno. Mi sve provjeravamo, pokrećemo i odgovaramo za svaki redak i tvrdnju.
- Seminar i prezentacija prate niti, pa svaki dio zajedno ima matematiku, kod i sliku.
- Imamo tri zajednička prolaza: nakon prve faktorizacije, nakon strukture i prije obrane. Na svakom nit objašnjava netko tko joj nije nositelj.
- Svatko mora moći objasniti cijeli projekt, pa na probnoj obrani dobiva pitanja iz tuđih niti.

- Radimo u malim zadacima, svaki na svojoj grani, a PR odobrava drugi član tima. Pitanja i hipoteze zapisujemo prije završnih pokretanja.

Redoslijed: izbor teme, nit 1, nit 2, nit 3, završni seminar i prezentacija, zatim ponovno pokretanje svih rezultata i probna obrana. Rok još ne znamo, pa ovo nije vremenski plan.

Trebamo odlučiti: koju temu biramo, tko je u početku nositelj koje niti te koji su rok i format predaje.

Izvori

Literatura seminara. L1: N. Gillis, *The Why and How of Nonnegative Matrix Factorization*, arXiv:1401.5226v2. L3: D. D. Lee, H. S. Seung, *Algorithms for Non-negative Matrix Factorization*. L4: M. W. Berry, M. Browne, A. N. Langville, V. P. Pauca, R. J. Plemmons, *Algorithms and Applications for Approximate Nonnegative Matrix Factorization*. L5: W. Xu, X. Liu, Y. Gong, *Document Clustering Based On Non-negative Matrix Factorization*, SIGIR 2003. L6: D. Kuang, B. Drake, H. Park, *Fast Clustering and Topic Modeling Based on Rank-2 Nonnegative Matrix Factorization*, 2015.

Dodatno. A. Vahadane i sur., *Structure-Preserving Color Normalization and Sparse Stain Separation for Histological Images*, IEEE TMI, 2016. M. Macenko i sur., ISBI 2009, doi:10.1109/ISBI.2009.5193250. Q. Xi i sur., *GuitarSet: A Dataset for Guitar Transcription*, ISMIR 2018.

Podaci. Sentinel-2 L2A: `https://earth-search.aws.element84.com/v1`; ESA WorldCover: `https://zenodo.org/records/7254221`; GuitarSet: `https://zenodo.org/records/3371780`; Lichess: `https://database.lichess.org/`; NCT-CRC-HE-100K: `https://zenodo.org/records/1214456`.