NMF i prepisivanje gitare: skripta za obranu

Matrične i tenzorske metode u analizi podataka · tema 2 iz prijedloga tema · radni nacrt, 5. studenoga 2026.

O ovoj skripti

- Skripta pokriva matematiku koju trebamo znati ako odaberemo temu 2 iz prijedloga tema: automatsko prepisivanje snimke akustične gitare u note pomoću nenegativne matrične faktorizacije (NMF). **Tema još nije odabrana**, pa ni izbori opisani ovdje (veličina prozora, način učenja predložaka, prag) nisu odluke tima, nego prijedlozi.
- Pretpostavlja se samo preddiplomsko predznanje: linearna algebra, analiza funkcija više varijabli i osnovna vjerojatnost. Fourierovu transformaciju, konveksnost, Jensenovu nejednakost i uvjete optimalnosti uvodimo u tekstu.
- **Dio I** gradi intuiciju redoslijedom kojim teče projekt: od zvuka do matrice, od matrice do faktorizacije, od faktorizacije do nota. **Dio II** istim redoslijedom daje definicije, tvrdnje i dokaze. Na početku svakog odjeljka stoji poveznica na pripadni odjeljak drugog dijela.
- Oznake L1–L4 odnose se na priložene radove iz vodiča kroz literaturu (`docs/research/LITERATURE.md`). Uz svaku tvrdnju piše odakle je; *vlastiti izvod* znači da tvrdnje u tom obliku nema u priloženim radovima. Izvore izvan priloženih radova treba pročitati i provjeriti prije citiranja u seminaru.
- Nijedan eksperiment još nije pokrenut, pa skripta ne sadrži rezultate. Nitko iz tima je još nije pregledao.

Sadržaj

I Intuitivni pregled **3**

1 Problem: od zvuka do nota **3**

1.1 Ton, frekvencija i harmonici . . . 3

1.2 Zašto je to teško . . . 3

2 Od zvuka do nenegativne matrice **4**

2.1 Uzorkovanje i Fourierova ideja . . . 4

2.2 Prozori i spektrogram . . . 4

2.3 Zašto modul i zašto „približno zbroj“ . . . 5

3 Model $A \approx WH$ **5**

3.1 Predlošci i aktivacije . . . 5

3.2 Zašto nenegativnost . . . 5

3.3 Što je r . . . 6

4 Kako mjeriti koliko je WH blizu A **6**

5 Kako naći W i H **7**
5.1 Težak problem s laganim dijelovima . . . 7
5.2 Multiplikativno pravilo i kako ga čitati . . . 7
5.3 Zašto se funkcija cilja ne povećava . . . 8
5.4 Mali primjer . . . 8

6 Što je zajamčeno, a što nije **8**

7 Od teorije do transkripcije **9**
7.1 Podaci i podjela . . . 9
7.2 Učenje predložaka (prijedlog, nije odluka) . . . 9
7.3 Transkripcija nove snimke . . . 10
7.4 Vrednovanje . . . 10
7.5 Što očekivati . . . 10

8 Sažetak u deset rečenica **10**

II Formalni pregled **11**

9 Oznake i alati **11**
9.1 Matrice . . . 11
9.2 Konveksnost . . . 11

10 Signal, DFT i spektrogram **12**

11 NMF i funkcije cilja **13**

12 Struktura problema **14**

13 Uvjeti optimalnosti **15**

14 Multiplikativna pravila ažuriranja **16**
14.1 Izvod iz gradijentnog koraka . . . 16
14.2 Svojstva . . . 16

15 Monotonost: metoda pomoćne funkcije **17**

16 Što jest, a što nije dokazano o konvergenciji **19**

17 Praktični detalji algoritma **19**

18 Primjena: učenje, transkripcija i vrednovanje **20**

18.1 Matrica za učenje i maskirani NMF 20
18.2 Transkripcija 20
18.3 Mjere uspjeha 21
18.4 Plan vrednovanja 21

A Karta literature **21**

B Pitanja za obranu **22**

Dio I

Intuitivni pregled

1. Problem: od zvuka do nota

Formalno: odjeljak 10.

Glazbenik svira akustičnu gitaru, a mi imamo samo snimku zvuka. Želimo automatski dobiti popis odsviranih nota: za svaku notu njezinu *visinu*, *trenutak početka* i *trenutak kraja*. Takav se popis često crta kao *klavirska rola*: vodoravna os je vrijeme, okomita os visina tona, a svaka nota je vodoravna crta. Zadatak se zove automatska transkripcija glazbe.

Pitanje teme 2 glasi: **može li NMF iz snimke prepoznati koje tonove glazbenik svira i kada, i koliko to dobro radi na gitaristu kojeg model nije vidio tijekom učenja?**

1.1 Ton, frekvencija i harmonici

Zvuk je titranje tlaka zraka; mikrofon ga bilježi kao funkciju vremena $x(t)$. Žica koja titra osnovnom frekvencijom f_0 ne proizvodi samo sinusoidu frekvencije f_0, nego i njezine *harmonike*: sinusoide frekvencija $2f_0, 3f_0, 4f_0, \dots$, obično sve slabije. Ton zato u frekvencijskom prikazu izgleda kao *češalj* (slika 1). Položaj zubaca određuje visinu tona, a njihove relativne visine boju zvuka: ista nota na gitari i klaviru ima zupce na istim mjestima, ali različitih visina.

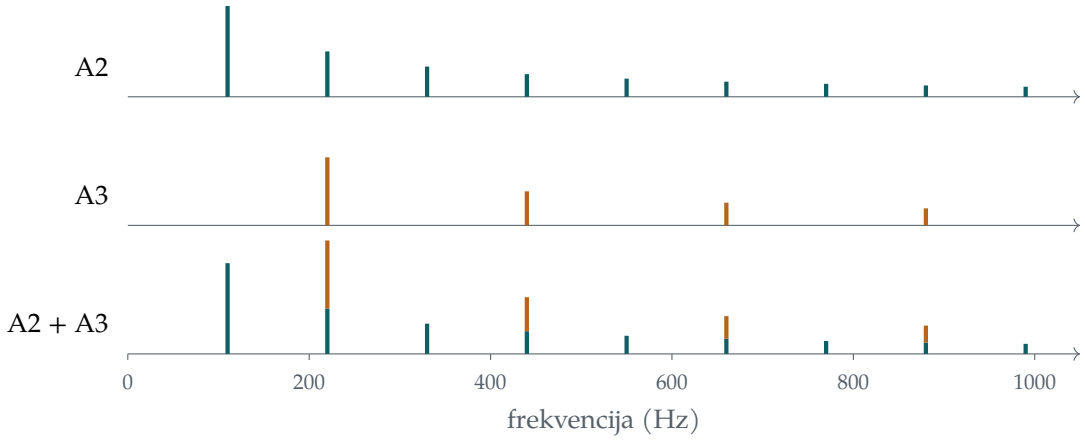
Visinu tona zapisujemo cijelim brojem p (MIDI broj). Pripadna osnovna frekvencija je

$$f(p) = 440 \cdot 2^{(p-69)/12} \text{ Hz}.$$

Susjedne note (razmak od jednog polustepena) razlikuju se faktorom $2^{1/12} \approx 1{,}059$, a oktava je udvostručenje frekvencije. Gitara u standardnom ugađanju ima prazne žice E2, A2, D3, G3, B3 i E4 (MIDI 40, 45, 50, 55, 59, 64). Najniži ton E2 ima oko 82,4 Hz. Uz dvadesetak pragova najviši su tonovi oko MIDI 84 (oko 1047 Hz), pa na gitari postoji nekoliko desetaka mogućih visina. Točan raspon odredit ćemo iz podataka.

1.2 Zašto je to teško

- **Polifonija.** Na gitari često zvuči više nota istodobno (akordi), pa se njihovi spektri zbrajaju.
- **Preklapanje harmonika.** Nota oktavu iznad dijeli sve svoje harmonike s parnim harmonicima niže note (slika 1). Kod kvinte treći harmonik niže note gotovo se poklapa s drugim harmonikom više; u temperiranom ugađanju razlika je oko 2 centa (cent je stoti dio polustepena). Otuda tipične oktavne pogreške.



Slika 1: Idealizirani spektri tona A2 ($f_0 = 110$ Hz), tona A3 oktavu više ($f_0 = 220$ Hz) i njihova zbroja. Svaki harmonik tona A3 pada na parni harmonik tona A2, pa se u zbroju samo neki zupci povise. Zato je teško razlikovati „A2“ od „A2 + A3“. Visine zubaca su izmišljene.

- **Ista visina na različitim žicama.** Primjerice, E4 se može odsvirati na praznoj prvoj žici ili na petom pragu druge žice. Zvuk je sličan, ali ne i jednak.
- **Promjena kroz vrijeme.** Nakon trzaja ton naglo jača i zatim zamire, a viši harmonici zamiru brže od nižih. Spektar jedne note nije stalan.

2. Od zvuka do nenegativne matrice

Formalno: odjeljak 10.

2.1 Uzorkovanje i Fourierova ideja

Računalo pohranjuje zvuk kao niz uzoraka $x[\tau] = x(\tau/f_s)$, gdje je f_s frekvencija uzorkovanja, primjerice 44 100 uzoraka u sekundi. Osnovna ideja Fourierove analize jest da se svaki konačan niz od N uzoraka može zapisati kao zbroj N titraja frekvencija qf_s/N, $q = 0, \ldots, N-1$. Diskretna Fourierova transformacija (DFT) za svaku od tih frekvencija daje jedan kompleksan broj. Njegov modul kaže *koliko* te frekvencije ima u isječku, a argument *u kojoj je fazi*, odnosno koliko je titraj pomaknut u vremenu. Čista sinusoida frekvencije f_0 daje vrh oko indeksa $q \approx f_0 N/f_s$.

2.2 Prozori i spektrogram

Glazba se mijenja u vremenu, pa DFT ne računamo na cijeloj snimci, nego na kratkim isječcima. Uzmemo N uzoraka, pomnožimo ih *prozorom* koji glatko spušta rubove isječka na nulu (time smanjujemo razlijevanje vrha na susjedne frekvencije), izračunamo DFT, pomaknemo se za L uzoraka i ponovimo. To je *kratkotrajna Fourierova transformacija* (STFT). Module posložimo u matricu: redak i odgovara frekvencijskom binu, stupac j vremenskom okviru. Dobivena matrica A je *amplitudni spektrogram*. Njezini elementi su moduli, pa su **nenegativni**.

Duljina prozora nameće kompromis. Razmak susjednih binova je f_s/N, a vrh jedne sinusoide kroz Hannov prozor širok je oko četiri bina. Dvije bliske sinusoide jasno se razdvajaju tek kad im se frekvencije razlikuju za otprilike dva bina. Dulji prozor znači finije frekvencije, ali grublje vrijeme:

N (uz $f_s = 44\,100$)	razmak binova f_s/N	trajanje prozora	dva bina
2048	21,5 Hz	46 ms	43 Hz
4096	10,8 Hz	93 ms	22 Hz
8192	5,4 Hz	186 ms	11 Hz

Tonovi E2 i F2 razlikuju se za samo 4,9 Hz. Njihove osnovne frekvencije razdvojio bi tek prozor od preko trećine sekunde, a brze note traju kraće. Pomažu viši harmonici: h-ti harmonici dviju susjednih nota razlikuju se za h puta više herca. Izbor N i L zato je stvar mjerenja na podacima za učenje, a ne teorije.

2.3 Zašto modul i zašto „približno zbroj“

STFT je linearna: transformacija zbroja dvaju signala jednaka je zbroju transformacija. To vrijedi za kompleksne vrijednosti, a mi koristimo module. Modul zbroja općenito nije zbroj modula ($|z_1+z_2| \le |z_1|+|z_2|$), osim kad su faze jednake ili kad je jedan od brojeva nula. Dvije različite note uglavnom imaju energiju u *različitim* binovima, pa je u svakom binu jedan od dvaju doprinosa gotovo nula i moduli se približno zbrajaju. U binovima u kojima se harmonici preklapaju to ne vrijedi i model griješi.

Fazu odbacujemo jer se pri pomaku signala u vremenu mijenja, dok modul ostaje gotovo isti. Modul je stabilan opis toga *koliko čega ima*.

Ukratko

Snimka postaje matrica $A \in \mathbb{R}_{\ge 0}^{m\times n}$: m frekvencijskih binova, n vremenskih okvira. Element a_{ij} govori koliko frekvencije f_i ima u okviru j. Spektar zbroja nota približno je zbroj spektara nota.

3. Model $A \approx WH$

Formalno: odjeljak 11.

3.1 Predlošci i aktivacije

Pretpostavimo da svaka od r mogućih nota ima stalan spektralni *predložak* $w_k \in \mathbb{R}_{\ge 0}^{m}$ (njezin češalj) i da u okviru j zvuči jačinom $h_{kj} \ge 0$. Tada je spektar okvira

$$a_j \approx \sum_{k=1}^{r} h_{kj}\, w_k = W h_j,$$

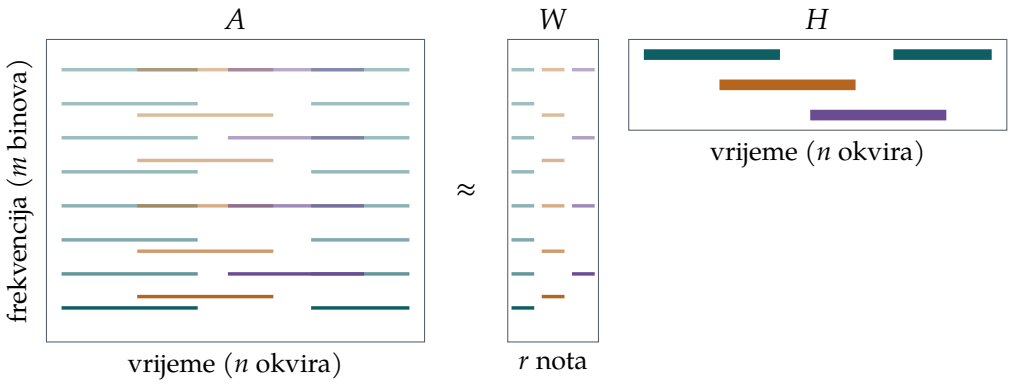
a za sve okvire odjednom $A \approx WH$. Stupci matrice $W \in \mathbb{R}_{\ge 0}^{m\times r}$ su predlošci, a retci matrice $H \in \mathbb{R}_{\ge 0}^{r\times n}$ aktivacije nota kroz vrijeme. Matrica H je, dakle, klavirska rola s jačinama (slika 2).

Red veličine: uz $N = 4096$ je $m = 2049$, minuta zvuka uz pomak $L = 512$ daje nekoliko tisuća okvira, a r je nekoliko desetaka. Model opisuje mn brojeva s $r(m+n)$ brojeva, dakle sažeto.

3.2 Zašto nenegativnost

Zvukovi se u modulu zbrajaju, a ne oduzimaju; aktivacija „minus jedan A2“ nema fizikalni smisao. Lee i Seung (L2) na primjerima pokazuju da nenegativnost vodi na prikaz *po dijelovima*: lica se rastavljaju na nos, oči i usta, a tekstovi na teme. Kod nas su dijelovi note.

Usporedba sa SVD-om je poučna. Skraćeni SVD daje najbolju aproksimaciju ranga r u Frobeniusovoj normi i računa se učinkovito (L1, odj. 3). Njegovi vektori, međutim, imaju i negativne



Slika 2: Shema modela. Svaka od triju nota ima češalj (stupac od W) i razdoblja u kojima zvuči (redak od H). Spektrogram A je zbroj umnožaka. Treća nota (ljubičasta) oktavu je iznad prve (plave), pa joj svi zupci padaju na zupce prve note. Shema je izmišljena, nisu to stvarni podaci.

elemente: opisuju cjeline koje se međusobno poništavaju i ne mogu se čitati kao note. NMF zbog dodatnih ograničenja daje lošiju aproksimaciju u toj normi, ali faktori mogu imati fizikalno značenje, i to *ako model vrijedi*. Nenegativnost sama po sebi ne jamči smislene komponente.

3.3 Što je r

Kod nenadziranog NMF-a rang r treba odabrati, što nije lako (L1, odj. 3). Kod nas r određuje raspon gitare: jedan predložak po visini tona, ili nekoliko po visini ako želimo razlikovati žice. To je jedan od razloga za *nadzirano* učenje predložaka (odjeljak 7).

4. Kako mjeriti koliko je WH blizu A

Formalno: odjeljak 11.

Trebamo mjeru odstupanja koja se zbraja po elementima: $\sum_{i,j} d(a_{ij} \,\|\, b_{ij})$, uz $B = WH$.

Frobeniusova norma, $d(a\|b) = \frac{1}{2}(a-b)^2$, poznata je metoda najmanjih kvadrata. Statistički odgovara pretpostavci da je šum Gaussov i jednako jak u svakom elementu.

Generalizirana Kullback–Leiblerova (KL) divergencija (L3, odj. 3) jest

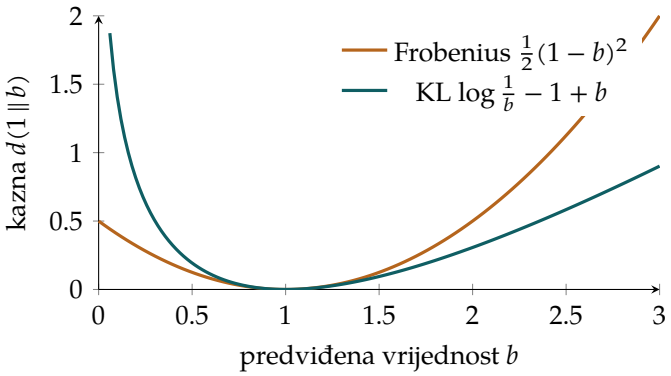
$$d(a \,\|\, b) = a \log \frac{a}{b} - a + b.$$

Ona je nenegativna i jednaka nuli samo za $a = b$, ali nije simetrična (slika 3). Ako model u binu u kojem ima energije ($a > 0$) predvidi $b \to 0$, kazna raste u beskonačnost: model ne smije „zaboraviti“ energiju. Ako predvidi previše, kazna raste samo linearno.

Ljestvica. Najvažnija razlika je u tome kako se kazna mijenja s glasnoćom. Pogledajmo pogrešku od 10 % u tihom i u stotinu puta glasnijem binu:

	$a = 1, b = 1{,}1$	$a = 100, b = 110$	omjer
Frobenius $\frac{1}{2}(a-b)^2$	0,005	50	10^4
generalizirana KL	0,0047	0,47	10^2

Frobeniusova kazna raste s kvadratom glasnoće, a KL linearno. Glazbeni spektrogram ima velik dinamički raspon: osnovni ton glasne note može biti stotinama puta jači od visokog harmonika tihe note. Uz Frobeniusovu normu algoritam se gotovo samo trudi oko najglasnijih binova, a KL



Slika 3: Kazna za jedan element uz izmjereno $a = 1$. Oko $b = 1$ obje se ponašaju jednako, ali KL jako kažnjava podcjenjivanje.

ravnomjernije raspoređuje pažnju. Itakura–Saitova divergencija, koju L1 spominje za analizu glazbe, potpuno je neovisna o ljestvici. Ne koristimo je, ali je dobra tema za pitanje „zašto baš KL“.

Statistička interpretacija. Minimizacija KL divergencije jednaka je traženju najveće izglednosti uz pretpostavku da je svaki a_{ij} Poissonova slučajna varijabla s očekivanjem $(WH)_{ij}$ (L2, jedn. (2)). To je motivacija, a ne dokaz da je KL „ispravna“ za naše podatke: moduli spektrograma nisu cijeli brojevi. Pravi test je kvaliteta transkripcije, pa u planu eksperimenata postoji usporedba s Frobeniusovom normom.

5. Kako naći W i H

Formalno: odjeljak 14.

5.1 Težak problem s laganim dijelovima

Rješavamo

$$\min_{W\geq 0,\ H\geq 0} D(A\,\|\,WH).$$

Taj problem je *nekonveksan*: ima mnogo minimuma (već zbog skaliranja, odjeljak 6) i može imati lokalne minimume i sedla. U općem slučaju NMF je NP-težak (L1, odj. 3), pa ne očekujemo algoritam koji uvijek nalazi globalni minimum. Međutim, **kad je W fiksiran, problem po H je konveksan** (L3, odj. 3), a u konveksnom problemu svaki je lokalni minimum globalni. Isto vrijedi za W uz fiksiran H. Zato algoritam *alternira*: malo popravi H, pa malo popravi W, i tako redom.

5.2 Multiplikativno pravilo i kako ga čitati

Pravilo za H (L3, teorem 2) glasi

$$h_{kj} \leftarrow h_{kj} \cdot \frac{\sum_i w_{ik} \dfrac{a_{ij}}{(WH)_{ij}}}{\sum_i w_{ik}}.$$

Omjer $a_{ij}/(WH)_{ij}$ veći je od 1 kad model u binu i okvira j objašnjava premalo energije, a manji od 1 kad objašnjava previše. Faktor kojim množimo h_{kj} ponderirani je prosjek tih omjera, a težine su predložak w_k: gledaju se samo binovi u kojima nota k ima harmonike. Ako je u tim binovima energija u prosjeku premalo objašnjena, aktivacija note raste, a ako je previše objašnjena, pada.

Kad model savršeno objašnjava podatke, svi su omjeri 1 i ništa se ne mijenja. Pravilo za W je analogno.

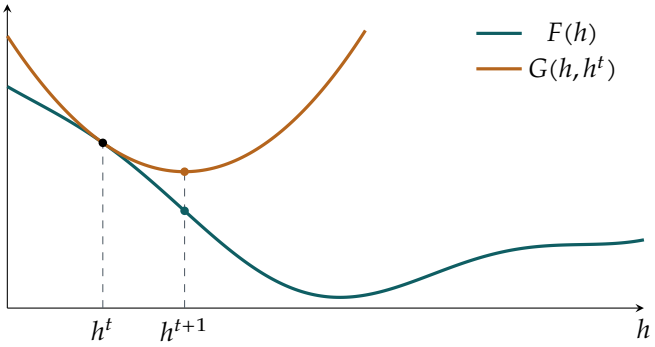
Pravilo je zapravo korak gradijentnog spusta u kojem svaki element ima svoju duljinu koraka, odabranu tako da se oduzimanje pokrati i ostane samo množenje. Zato nenegativnost ostaje sama od sebe, bez projekcija, i ne treba ručno birati duljinu koraka.

5.3 Zašto se funkcija cilja ne povećava

Ključna ideja zove se *majorizacija–minimizacija* (slika 4). U trenutnoj točki h^t konstruiramo jednostavnu funkciju $G(\cdot, h^t)$ koja leži iznad funkcije cilja F i dodiruje je u h^t. Zatim minimiziramo G umjesto F. Tada

$$F(h^{t+1}) \le G(h^{t+1}, h^t) \le G(h^t, h^t) = F(h^t).$$

Za KL divergenciju takva se G dobije iz Jensenove nejednakosti za logaritam, a njezin minimum je upravo multiplikativno pravilo (L3, odj. 6). Cijeli dokaz je u odjeljku 15.



Slika 4: Majorizacija–minimizacija. Pomoćna funkcija G dodiruje F u h^t i nigdje nije ispod nje. Njezin minimum h^{t+1} zato ne može povećati F. Funkcije su ilustrativne.

5.4 Mali primjer

Neka postoje dva bina i dva predloška: $w_1 = (1, 1)$ je nota s energijom u oba bina, a $w_2 = (1, 0)$ nota samo u prvom. Izmjereno je $a = (2, 1) = w_1 + w_2$, pa je točno rješenje $h = (1, 1)$ uz $D = 0$. Krenemo li od $h^0 = (1,\ 1/5)$, multiplikativno pravilo daje $D = 0{,}2217 \to 0{,}0770 \to 0{,}0627 \to 0{,}0491 \to \cdots \to 0$ (primjer 14.3). Vrijednost pada u svakom koraku, ali sve sporije. Multiplikativna pravila su poznata po sporosti (L1, odj. 3.1.2; L4, odj. 3.1).

6. Što je zajamčeno, a što nije

Formalno: odjeljak 16.

Ovo je najvažniji odjeljak za obranu. Lako je reći više nego što je dokazano.

Tvrdnja	Vrijedi?	Izvor
Funkcija cilja se ni u jednom koraku ne povećava	Da, uz blage pretpostavke	L3, teorem 2
Niz vrijednosti funkcije cilja konvergira	Da (monoton, omeđen nulom)	elementarno
Iterati (W^t, H^t) konvergiraju	Nije dokazano	L4, odj. 3.1
Granična točka je stacionarna	Dokazano samo za točke s pozitivnim elementima	L4, odj. 3.1; ovdje prop. 16.1
Dobivamo lokalni minimum	Nije dokazano (L3 to tvrdi, L4 ispravlja)	L3, odj. 6; L4, odj. 3.1
Dobivamo globalni minimum	Općenito ne	L1, odj. 3
Faktori su jedinstveni	Ne	L1, odj. 3
Uz fiksiran W problem po H je konveksan	Da	L3, odj. 3

Zamka s nulama. Ako h_{kj} u nekom koraku postane 0, multiplikativno pravilo ga više nikad ne pomiče. Algoritam tako može zapeti u točki koja nije ni stacionarna. U malom primjeru, krenemo li od $h^0 = (1, 0)$, već u prvom koraku stižemo u $(3/2, 0)$ i tamo ostajemo zauvijek, uz $D \approx 0{,}17$, iako je minimum 0 (primjer 16.2). Pouka: inicijaliziramo pozitivnim brojevima. Nule koje stavljamo namjerno, kao u odjeljku 7, koriste baš to svojstvo.

Nejedinstvenost. Za svaku pozitivnu dijagonalnu matricu Λ vrijedi $WH = (W\Lambda)(\Lambda^{-1}H)$, a i stupci od W mogu se permutirati zajedno s retcima od H. Skaliranje uklanjamo normalizacijom: zbroj svakog stupca od W postavimo na 1, a H odgovarajuće prilagodimo. Tada je h_{kj} ukupna „masa“ note k u okviru j. Permutacija kod nas ne smeta jer predloške učimo iz oznaka, pa je stupac k po konstrukciji nota k.

Na obrani pazi

- Ne govori „algoritam konvergira lokalnom minimumu“. Reci: „funkcija cilja ne raste; ako iterati konvergiraju prema točki s pozitivnim elementima, ta je točka stacionarna“.
- Stacionarna točka nije nužno lokalni minimum. Primjerice, $(W, H) = (0, 0)$ je stacionarna točka Frobeniusove funkcije cilja (primjer 13.5).
- Nenegativnost ne jamči da su predlošci „prave note“; to provjeravamo na podacima.
- Težine h_{kj} nisu vjerojatnosti.

7. Od teorije do transkripcije

Formalno: odjeljak 18.

7.1 Podaci i podjela

Skup GuitarSet (CC BY 4.0) ima 360 snimaka šest gitarista s označenim notama. Predloške učimo na pet gitarista, a transkripciju provjeravamo na šestom, i to ponavljamo za svakog gitarista (šest podjela). Tako mjerimo radi li metoda na sviraču kojeg nije vidjela.

7.2 Učenje predložaka (prijedlog, nije odluka)

Maskirani NMF. Za snimke za učenje iz oznaka znamo koja nota zvuči u kojem okviru. Tu informaciju zapišemo kao matricu $M \in \{0, 1\}^{r \times n}$. Matricu H inicijaliziramo pozitivnim broje-

vima samo tamo gdje je $M_{kj} = 1$, a nulama drugdje. Budući da multiplikativno pravilo čuva nule, aktivacija note koja ne svira ostaje 0. Algoritam mora objasniti spektar samo notama koje stvarno zvuče, i tako uči njihove predloške. Teorem o nerastu i dalje vrijedi (propozicija 18.1). Dvije praktične zamke:

- Okvir u kojem ne svira nijedna nota, a ima malo šuma, daje beskonačnu divergenciju. Treba dodati jednu komponentu za pozadinski šum koja je uvijek aktivna ili takve okvire izbaciti.
- Notu koja se u skupu za učenje ne pojavljuje nije moguće naučiti.

Jednostavnija mogućnost: predložak note je prosjek normaliziranih spektara okvira u kojima svira samo ta nota. Oba načina mogu se proširiti na više predložaka po visini, primjerice po žici.

7.3 Transkripcija nove snimke

Za snimku novog gitarista izračunamo spektrogram A', **fiksiramo naučeni** W i rješavamo samo $\min_{H \geq 0} D(A' \,\|\, WH)$. Taj je problem konveksan: svaki lokalni minimum je globalni, pa za razliku od punog problema nema lošijih lokalnih minimuma u kojima bismo mogli zapeti. Zatim:

1. notu k proglasimo aktivnom u okviru j ako je h_{kj} iznad praga θ;
2. uzastopne aktivne okvire spojimo u jednu notu s početkom i krajem;
3. odbacimo prekratke note.

Prag θ i najmanju duljinu note biramo na gitaristima za učenje, **nikad na testnom**.

7.4 Vrednovanje

Procijenjena nota je *pogodak* ako ima istu visinu kao neka stvarna nota i počinje dovoljno blizu njezinu početku; uobičajena tolerancija je 50 ms. Svaka stvarna nota smije se upariti s najviše jednom procijenjenom. Tada je

$$P = \frac{\text{pogoci}}{\text{sve procijenjene note}}, \qquad R = \frac{\text{pogoci}}{\text{sve stvarne note}}, \qquad F_1 = \frac{2PR}{P + R}.$$

Preciznost P kažnjava izmišljene note, a odziv R propuštene. Prijavljujemo F_1 za svakog od šest gitarista i prosjek, a ne samo najbolji slučaj. Uspoređujemo se s istim postupkom uz Frobeniusovu normu i s jednostavnim odabirom spektralnih vrhova.

7.5 Što očekivati

Očekujemo oktavne pogreške, probleme s akordima, s istom notom na različitim žicama i sa zamiranjem tona. Skroman F_1 legitiman je rezultat ako je pošteno izmjeren i analiziran.

8. Sažetak u deset rečenica

Za ponavljanje prije obrane

1. Snimku pretvaramo u amplitudni spektrogram $A \geq 0$; retci su frekvencije, stupci vrijeme.
2. Spektar više nota približno je zbroj spektara nota jer se njihova energija uglavnom nalazi u različitim binovima.
3. Model $A \approx WH$: stupci od W su predlošci nota, retci od H njihove aktivacije.

4. Odstupanje mjerimo generaliziranom KL divergencijom koja, za razliku od Frobeniusove norme, ne pušta da najglasniji binovi dominiraju.
5. Puni problem je nekonveksan i NP-težak, ali je uz fiksiran W konveksan po H.
6. Multiplikativna pravila su skalirani gradijentni koraci koji automatski čuvaju nenegativnost.
7. Funkcija cilja ne raste jer je svaki korak minimum pomoćne funkcije koja leži iznad nje.
8. Nije dokazano da iterati konvergiraju, ni da je granica lokalni minimum; nule ostaju nule.
9. Predloške učimo iz označenih snimaka, a novu snimku obrađujemo rješavanjem konveksnog problema po H i pragom.
10. Uspjeh mjerimo s F_1 na razini nota, odvojeno za svakog gitarista kojeg model nije vidio.

Dio II

Formalni pregled

9. Oznake i alati

9.1 Matrice

$\mathbb{R}^{m\times n}_{\geq 0}$ je skup realnih $m \times n$ matrica s nenegativnim elementima; $A \geq 0$ i $A > 0$ znače da su svi elementi nenegativni, odnosno pozitivni. Stupac j matrice A označavamo s a_j, a redak k matrice H s $H_{k,:}$. Za matrice istih dimenzija

$$(X \odot Y)_{ij} = x_{ij}y_{ij}, \qquad (X \oslash Y)_{ij} = x_{ij}/y_{ij},$$

a $\mathbf{1}$ je matrica (ili vektor) jedinica odgovarajućih dimenzija. Skalarni produkt matrica je $\langle X, Y\rangle = \sum_{ij} x_{ij}y_{ij} = \operatorname{tr}(X^T Y)$, a Frobeniusova norma $\|X\|_F = \langle X, X\rangle^{1/2}$.

Za funkciju f matrične varijable X, gradijent $\nabla_X f$ je matrica istih dimenzija kao X s elementima $\partial f/\partial x_{ij}$. Ekvivalentno, $f(X + \varepsilon E) = f(X) + \varepsilon\langle \nabla_X f, E\rangle + o(\varepsilon)$ za svaku matricu smjera E.

9.2 Konveksnost

Skup C je konveksan ako sadrži dužinu između bilo kojih dviju svojih točaka. Funkcija $f : C \to \mathbb{R}$ je konveksna ako je $f((1-t)x + ty) \leq (1-t)f(x) + tf(y)$ za sve $x, y \in C$ i $t \in [0,1]$, a konkavna ako je $-f$ konveksna. Koristimo sljedeće poznate činjenice:

- dvaput diferencijabilna funkcija na otvorenom konveksnom skupu konveksna je ako i samo ako joj je Hesseova matrica pozitivno semidefinitna u svakoj točki;
- zbroj konveksnih funkcija je konveksan, a $x \mapsto f(Mx + c)$ je konveksna ako je f konveksna;
- $-\log$ je konveksna na $(0,\infty)$ jer je $(-\log x)'' = 1/x^2 > 0$, pa je log konkavan.

Propozicija 9.1. *Ako je f konveksna na konveksnom skupu C, svaki lokalni minimum od f na C je globalni.*

Dokaz. Neka je x lokalni minimum i neka postoji $y \in C$ s $f(y) < f(x)$. Za $t \in (0,1]$ je $f(x + t(y-x)) \leq (1-t)f(x) + tf(y) < f(x)$, a točke $x + t(y-x)$ su za mali t po volji blizu x. To je u kontradikciji s lokalnom minimalnošću. □

Propozicija 9.2 (Jensenova nejednakost). *Ako je φ konkavna, $z_1, \dots, z_s$ iz njezine domene, a $\lambda_k \geq 0$ uz $\sum_k \lambda_k = 1$, tada je $\varphi(\sum_k \lambda_k z_k) \geq \sum_k \lambda_k \varphi(z_k)$.*

Dokaz. Za $s = 2$ to je definicija konkavnosti. Korak indukcije: za $\lambda_s < 1$ zapišemo $\sum_k \lambda_k z_k = (1-\lambda_s) \sum_{k<s} \frac{\lambda_k}{1-\lambda_s} z_k + \lambda_s z_s$ i primijenimo slučaj $s = 2$, a zatim pretpostavku indukcije. □

Koristit ćemo i činjenicu da monoton i omeđen niz realnih brojeva konvergira.

10. Signal, DFT i spektrogram

Intuicija: odjeljak 2.

U ovom odjeljku i je imaginarna jedinica, a frekvencijske binove indeksiramo s q jer počinju od nule.

Definicija 10.1 (DFT). Za $y \in \mathbb{C}^N$ diskretna Fourierova transformacija je

$$\hat{y}[q] = \sum_{\tau=0}^{N-1} y[\tau]\, e^{-2\pi \mathrm{i}\, q\tau/N}, \qquad q = 0, \dots, N-1.$$

Propozicija 10.2. *(a) DFT je linearna: $\widehat{\alpha y + \beta z} = \alpha\hat{y} + \beta\hat{z}$.*

(b) Vrijedi formula inverzije $y[\tau] = \frac{1}{N} \sum_{q=0}^{N-1} \hat{y}[q]\, e^{2\pi \mathrm{i}\, q\tau/N}$. Dakle y je kombinacija N kompleksnih titraja; uz frekvenciju uzorkovanja f_s titraj s indeksom q ima frekvenciju qf_s/N.

(c) Ako je y realan, tada je $\hat{y}[N-q] = \overline{\hat{y}[q]}$, pa je za paran N dovoljno promatrati $q = 0, \dots, N/2$.

Dokaz. (a) je očito. (b) slijedi iz $\sum_{\tau=0}^{N-1} e^{2\pi \mathrm{i}(q-q')\tau/N} = N$ za $q = q'$ i 0 inače (zbroj geometrijskog niza). (c) $e^{-2\pi \mathrm{i}(N-q)\tau/N} = e^{2\pi \mathrm{i} q\tau/N} = \overline{e^{-2\pi \mathrm{i} q\tau/N}}$, a $y[\tau]$ su realni. □

Definicija 10.3 (STFT i spektrogram). Neka je $x[\tau]$ signal uzorkovan frekvencijom f_s, N paran broj, L pomak, a $g\colon \{0, \dots, N-1\} \to [0, \infty)$ prozor, npr. Hannov, $g[\tau] = \sin^2(\pi\tau/N)$. Za okvir $j = 0, \dots, n-1$ i bin $q = 0, \dots, N/2$:

$$X[q, j] = \sum_{\tau=0}^{N-1} x[jL + \tau]\, g[\tau]\, e^{-2\pi \mathrm{i}\, q\tau/N}, \qquad A_{qj} = |X[q, j]|.$$

Matrica $A \in \mathbb{R}_{\geq 0}^{m \times n}$, $m = N/2 + 1$, je amplitudni spektrogram. Bin q odgovara frekvenciji qf_s/N, a okvir j trenutku $(jL + N/2)/f_s$ (sredina prozora).

Propozicija 10.4 (sinusoida kroz prozor; vlastiti izvod). *Neka je $x[\tau] = c\cos(2\pi f_0 \tau/f_s + \phi)$ uz $c > 0$, neka je $\kappa_0 = f_0 N/f_s$ i $\hat{G}(\nu) = \sum_{\tau=0}^{N-1} g[\tau] e^{-2\pi \mathrm{i}\nu\tau/N}$ za realni ν. Tada je*

$$X[q, j] = \tfrac{c}{2} e^{\mathrm{i}\phi_j}\, \hat{G}(q - \kappa_0) + \tfrac{c}{2} e^{-\mathrm{i}\phi_j}\, \hat{G}(q + \kappa_0), \qquad \phi_j = \phi + 2\pi f_0 jL/f_s.$$

Pritom je $|\hat{G}(\nu)| \leq \hat{G}(0) = \sum_\tau g[\tau]$.

Dokaz. Napišemo $\cos\theta = \frac{1}{2}(e^{\mathrm{i}\theta} + e^{-\mathrm{i}\theta})$ uz $\theta = \phi_j + 2\pi\kappa_0\tau/N$, uvrstimo u definiciju i grupiramo eksponente. Nejednakost je nejednakost trokuta uz $g \geq 0$. □

Napomena 10.5. Za Hannov prozor je $\hat{G}(0) = N/2$, a $\hat{G}(\nu) = 0$ za cijele $|\nu| \geq 2$; glavni vrh zauzima interval $(\kappa_0 - 2, \kappa_0 + 2)$, dakle oko četiri bina. Ako κ_0 nije blizu 0 ni $N/2$, drugi je član zanemariv, pa je $A_{qj} \approx \frac{c}{2}|\hat{G}(q - \kappa_0)|$. To ne ovisi o fazi ϕ_j i zato je modul stabilan kroz okvire. Harmonijski ton $\sum_h c_h \cos(2\pi h f_0 \tau/f_s + \phi_h)$ po linearnosti daje vrhove oko $h\kappa_0$, dakle češalj. Dvije sinusoide jasno se razlikuju otprilike kad je $|\kappa_1 - \kappa_2| \gtrsim 2$, tj. $|f_1 - f_2| \gtrsim 2f_s/N$. To je pravilo iskustva, a ne teorem.

Propozicija 10.6 (zbrajanje modula)**.** *Za $z_1, z_2 \in \mathbb{C}$ je $|z_1 + z_2| \le |z_1| + |z_2|$, s jednakošću ako i samo ako je jedan od njih 0 ili imaju isti argument. Nadalje, $|z_1 + z_2|^2 = |z_1|^2 + |z_2|^2 + 2|z_1||z_2| \cos\Delta$, gdje je Δ razlika argumenata. Ako je Δ uniformno distribuiran na $[0, 2\pi)$, tada je $\mathbb{E}|z_1 + z_2|^2 = |z_1|^2 + |z_2|^2$.*

Dokaz. Prva tvrdnja je nejednakost trokuta u $\mathbb{C}$. Druga slijedi iz $|z_1 + z_2|^2 = (z_1 + z_2)\overline{(z_1 + z_2)}$. Za treću je $\mathbb{E}\cos\Delta = 0$. □

Posljedica: spektrogram zbroja nota je *točno* zbroj spektrograma samo ako note nemaju energiju u istim binovima ili ako su im faze jednake. Za kvadrate modula zbroj vrijedi u očekivanju uz nasumične faze. Model $A \approx WH$ je stoga aproksimacija, najlošija u binovima u kojima se harmonici preklapaju.

11. NMF i funkcije cilja

Intuicija: odjeljak 3.

Od sada retke od A indeksiramo s $i = 1, \dots, m$, stupce s $j = 1, \dots, n$, a komponente s $k = 1, \dots, r$.

Definicija 11.1 (NMF)**.** Za $A \in \mathbb{R}^{m\times n}_{\ge 0}$ i $r \in \mathbb{N}$ tražimo $W \in \mathbb{R}^{m\times r}_{\ge 0}$ i $H \in \mathbb{R}^{r\times n}_{\ge 0}$ koji minimiziraju odabranu mjeru odstupanja između A i WH. Promatramo

$$f_F(W,H) = \tfrac{1}{2}\|A - WH\|_F^2 \qquad \text{i} \qquad f_{KL}(W,H) = D(A \,\|\, WH).$$

Definicija 11.2 (generalizirana KL divergencija; L3, jedn. (3))**.** Za $A, B \ge 0$ istih dimenzija je $D(A \,\|\, B) = \sum_{ij} d(a_{ij} \,\|\, b_{ij})$, gdje je

$$d(a \,\|\, b) = a \log \frac{a}{b} - a + b,$$

uz dogovor $d(0 \,\|\, b) = b$ i $d(a \,\|\, 0) = +\infty$ za $a > 0$.

Propozicija 11.3. *$D(A \,\|\, B) \ge 0$, s jednakošću ako i samo ako je $A = B$.*

Dokaz. Dovoljno je promatrati jedan element. Za $a = 0$ je $d = b \ge 0$, s jednakošću ako i samo ako je $b = 0$. Za $a > 0$ i $b = 0$ je $d = \infty$. Za $a, b > 0$ zapišemo $d(a \,\|\, b) = b\,\psi(a/b)$ uz $\psi(x) = x \log x - x + 1$. Vrijedi $\psi'(x) = \log x$ i $\psi''(x) = 1/x > 0$, pa je ψ strogo konveksna s jedinim minimumom u $x = 1$, gdje je $\psi(1) = 0$. Dakle $d \ge 0$, s jednakošću ako i samo ako je $a = b$. □

Propozicija 11.4 (ljestvica; vlastiti izvod)**.** *Za $\lambda > 0$ je $D(\lambda A \,\|\, \lambda B) = \lambda D(A \,\|\, B)$ i $\|\lambda A - \lambda B\|_F^2 = \lambda^2 \|A - B\|_F^2$.*

Dokaz. Izravno iz definicija, jer je $\log \frac{\lambda a}{\lambda b} = \log \frac{a}{b}$. □

Napomena 11.5. Itakura–Saitova divergencija $\frac{a}{b} - \log\frac{a}{b} - 1$ ne mijenja se pri skaliranju. L1 (odj. 3) je navodi za analizu glazbe i upućuje na Févottea i suradnike [FBD]. U ovoj temi je ne koristimo.

Propozicija 11.6 (Poissonov model; usp. L2, jedn. (2))**.** *Neka su $a_{ij} \in \{0, 1, 2, \dots\}$ nezavisne Poissonove slučajne varijable s parametrima $b_{ij} = (WH)_{ij} > 0$. Tada je*

$$-\log \mathbb{P}(A \mid W, H) = D(A \,\|\, WH) + c(A),$$

gdje $c(A)$ ne ovisi o W i H. Minimizacija f_{KL} jednaka je maksimizaciji izglednosti.

Dokaz. $\mathbb{P}(A \mid W, H) = \prod_{ij} b_{ij}^{a_{ij}} e^{-b_{ij}} / a_{ij}!$, pa je $-\log \mathbb{P} = \sum_{ij}(b_{ij} - a_{ij}\log b_{ij} + \log a_{ij}!)$. Oduzmemo $D(A \,\|\, B) = \sum_{ij}(a_{ij}\log a_{ij} - a_{ij}\log b_{ij} - a_{ij} + b_{ij})$ i dobijemo $c(A) = \sum_{ij}(\log a_{ij}! - a_{ij}\log a_{ij} + a_{ij})$. □

Propozicija 11.7 (Gaussov model). *Ako je $a_{ij} = (WH)_{ij} + \varepsilon_{ij}$ uz nezavisne $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$, tada je $-\log p(A \mid W, H) = \sigma^{-2} f_F(W, H) + konst.$*

Dokaz. Logaritam umnoška gustoća $(2\pi\sigma^2)^{-1/2} \exp(-(a_{ij} - b_{ij})^2/(2\sigma^2))$. □

Napomena 11.8. Moduli spektrograma nisu cijeli brojevi ni Poissonove varijable, pa propozicija 11.6 samo motivira izbor KL divergencije. Odluku o funkciji cilja opravdava usporedba na podacima.

12. Struktura problema

Intuicija: odjeljak 5.

Propozicija 12.1 (nejedinstvenost; L1, odj. 3). *Ako je P matrica permutacije, a Λ dijagonalna matrica s pozitivnom dijagonalom, tada su $W' = WP\Lambda \geq 0$ i $H' = \Lambda^{-1}P^T H \geq 0$ te $W'H' = WH$.*

Dokaz. $P\Lambda\Lambda^{-1}P^T = PP^T = I$; množenje nenegativnih matrica s P i pozitivnom dijagonalom čuva nenegativnost. □

Napomena 12.2. Mogu postojati i druge invertibilne Q s $WQ \geq 0$ i $Q^{-1}H \geq 0$; tada su faktorizacije bitno različite, s različitom interpretacijom (L1, odj. 3, s primjerom 3×4). Kod nas nadzirano učenje određuje poredak stupaca, a normalizacija skaliranje.

Propozicija 12.3 (normalizacija). *Neka W nema nul-stupac, $s_k = \sum_i w_{ik}$ i $S = \operatorname{diag}(s)$. Za $W' = WS^{-1}$ i $H' = SH$ vrijedi $W'H' = WH$, zbroj svakog stupca od W' je 1 i $h'_{kj} = \sum_i w_{ik} h_{kj}$. Vrijednosti funkcija cilja se ne mijenjaju.*

Dokaz. Poseban slučaj propozicije 12.1 uz $P = I$, $\Lambda = S^{-1}$. □

Primjer 12.4 (nekonveksnost; vlastiti izvod). Neka je $m = n = r = 1$ i $a = 1$. Tada je na $(0, \infty)^2$

$$f(w, h) = d(1 \,\|\, wh) = -\log w - \log h - 1 + wh, \qquad \nabla^2 f = \begin{pmatrix} 1/w^2 & 1 \\ 1 & 1/h^2 \end{pmatrix}.$$

Determinanta $1/(w^2h^2) - 1$ negativna je za $wh > 1$, pa Hesseova matrica tamo ima negativnu svojstvenu vrijednost i f nije konveksna. Skup minimuma $\{wh = 1\}$ je hiperbola: beskonačno mnogo minimuma, što je upravo nejedinstvenost skaliranja. Za Frobeniusovu normu, $f = \frac{1}{2}(1 - wh)^2$ ima u $(0, 0)$ Hesseovu matricu $\left(\begin{smallmatrix} 0 & -1 \\ -1 & 0 \end{smallmatrix}\right)$ sa svojstvenim vrijednostima ± 1.

Napomena 12.5 (složenost; L1, odj. 3). NMF je u općem slučaju NP-težak (Vavasis [Vav], prema L1). Zato koristimo lokalne metode s jamstvima koja navodimo u odjeljku 16.

Propozicija 12.6 (konveksni potproblemi; L3, odj. 3; L1, odj. 3.1). *Neka je $W \geq 0$ fiksiran i $I_+(j) = \{i : a_{ij} > 0\}$. Tada je*

$$D(A \,\|\, WH) = \sum_{j=1}^{n} D(a_j \,\|\, Wh_j),$$

a svaka funkcija $h \mapsto D(a_j \,\|\, Wh)$ konveksna je na konveksnom skupu $\{h \geq 0 : (Wh)_i > 0 \ \forall i \in I_+(j)\}$. Funkcija $H \mapsto \frac{1}{2}\|A - WH\|_F^2$ konveksna je na $\mathbb{R}^{r \times n}_{\geq 0}$. Za fiksiran H vrijedi isto po W, jer je $D(A \,\|\, WH) = D(A^T \,\|\, H^T W^T)$ i $\|A - WH\|_F = \|A^T - H^T W^T\|_F$.

Dokaz. Rastav po stupcima slijedi iz $(WH)_{ij} = (Wh_j)_i$. Za $i \in I_+(j)$ član $a_{ij}\log a_{ij} - a_{ij}\log(Wh)_i - a_{ij} + (Wh)_i$ je zbroj konstante, funkcije $-\log$ primijenjene na linearnu funkciju od h (konveksno, jer je $a_{ij} > 0$) i linearne funkcije. Za $i \notin I_+(j)$ član je $(Wh)_i$, dakle linearan. Zbroj konveksnih je konveksan. Skup je presjek $\mathbb{R}^r_{\geq 0}$ s poluprostorima $\{(Wh)_i > 0\}$, pa je konveksan. Frobeniusov slučaj: kvadrat norme je konveksan, a $H \mapsto A - WH$ afino preslikavanje. □

Propozicija 12.7 (gradijenti). *Uz dogovor $a_{ij}/(WH)_{ij} = 0$ kad je $a_{ij} = 0$, na skupu na kojem je f_{KL} konačna vrijedi*

$$\nabla_H f_{KL} = W^T(\mathbf{1} - A \oslash (WH)), \qquad \nabla_W f_{KL} = (\mathbf{1} - A \oslash (WH))H^T,$$

gdje je $\mathbf{1}$ matrica jedinica dimenzija $m \times n$. Za Frobeniusovu normu

$$\nabla_H f_F = W^T(WH - A), \qquad \nabla_W f_F = (WH - A)H^T.$$

Dokaz. Element h_{kj} pojavljuje se samo u $(WH)_{ij} = \sum_l w_{il}h_{lj}$, uz $\partial(WH)_{ij}/\partial h_{kj} = w_{ik}$. Zato je

$$\frac{\partial f_{KL}}{\partial h_{kj}} = \sum_i w_{ik}\Big(1 - \frac{a_{ij}}{(WH)_{ij}}\Big),$$

što je element (k,j) matrice $W^T(\mathbf{1} - A \oslash WH)$. Za f_F je $f_F(W, H+\varepsilon E) = f_F(W,H) + \varepsilon\langle WH - A, WE\rangle + O(\varepsilon^2)$, a $\langle WH - A, WE\rangle = \langle W^T(WH - A), E\rangle$. Gradijenti po W slijede transponiranjem. □

U oba slučaja gradijent je razlika dviju nenegativnih matrica, $\nabla = \nabla^+ - \nabla^-$:

$$\nabla^+_H f_{KL} = W^T\mathbf{1}, \quad \nabla^-_H f_{KL} = W^T(A \oslash WH), \qquad \nabla^+_H f_F = W^TWH, \quad \nabla^-_H f_F = W^TA.$$

13. Uvjeti optimalnosti

Intuicija: odjeljak 6.

Teorem 13.1 (nužni uvjeti na nenegativnom ortantu). *Neka je $\Omega \subseteq \mathbb{R}^p$ otvoren, $f\colon \Omega \to \mathbb{R}$ diferencijabilna i $x^* \in \Omega \cap \mathbb{R}^p_{\geq 0}$ lokalni minimum od f na $\Omega \cap \mathbb{R}^p_{\geq 0}$. Tada*

$$x^* \geq 0, \qquad \nabla f(x^*) \geq 0, \qquad x^* \odot \nabla f(x^*) = 0.$$

Dokaz. Promotrimo $\varphi(t) = f(x^* + te_k)$ za $t \geq -x^*_k$ blizu 0. Točka $t = 0$ je lokalni minimum od φ. Ako je $x^*_k > 0$, 0 je unutarnja točka, pa je $\varphi'(0) = \partial_k f(x^*) = 0$. Ako je $x^*_k = 0$, smijemo ići samo u $t > 0$; kad bi bilo $\varphi'(0) < 0$, za mali $t > 0$ bilo bi $\varphi(t) < \varphi(0)$. Dakle $\partial_k f(x^*) \geq 0$. U oba slučaja je $x^*_k\,\partial_k f(x^*) = 0$. □

Teorem 13.2 (dovoljnost uz konveksnost). *Ako je uz to $C = \Omega \cap \mathbb{R}^p_{\geq 0}$ konveksan, a f konveksna na C, tada je svaka točka koja zadovoljava uvjete teorema 13.1 globalni minimum od f na C.*

Dokaz. Za konveksnu diferencijabilnu f i $x, y \in C$ iz definicije konveksnosti slijedi

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x), \qquad t \in (0,1],$$

pa puštanjem $t \to 0^+$ dobijemo $f(y) \geq f(x) + \nabla f(x)^T(y - x)$. Uz $x = x^*$ je $\nabla f(x^*)^T x^* = 0$ i $\nabla f(x^*)^T y \geq 0$, pa je $f(y) \geq f(x^*)$. □

Definicija 13.3 (stacionarna točka NMF-a; L1, odj. 3.1.1). Par (W,H) je stacionarna točka problema NMF ako vrijedi

$$W \geq 0,\ \nabla_W f \geq 0,\ W \odot \nabla_W f = 0, \qquad H \geq 0,\ \nabla_H f \geq 0,\ H \odot \nabla_H f = 0.$$

Korolar 13.4. *Svaki lokalni minimum problema NMF je stacionarna točka. Za fiksiran W je svaka stacionarna točka problema po H njegov globalni minimum.*

Dokaz. Lokalni minimum po (W,H) je lokalni minimum po svakom bloku posebno, pa primijenimo teorem 13.1. Druga tvrdnja slijedi iz propozicije 12.6 i teorema 13.2. □

Primjer 13.5 (stacionarna točka koja nije minimum; vlastiti izvod). Neka je $A \geq 0$, $A \neq 0$ i $f = f_F$. U $(W,H) = (0,0)$ su oba gradijenta nula, pa je to stacionarna točka. Nije lokalni minimum: uz $a_{ij} > 0$ i $W = \varepsilon e_i e_1^T$, $H = \varepsilon e_1 e_j^T$ je $WH = \varepsilon^2 e_i e_j^T$ i $f_F = \frac{1}{2}\|A\|_F^2 - \varepsilon^2 a_{ij} + \frac{1}{2}\varepsilon^4 < f_F(0,0)$ za mali $\varepsilon > 0$.

Napomena 13.6. L4 (odj. 3.4) kaže da je rješenje koje zadovoljava uvjete optimalnosti „barem lokalni minimum". Primjer 13.5 pokazuje da to za uvjete prvog reda ne vrijedi. Uvjet komplementarnosti objašnjava i zašto NMF često daje rijetke faktore: svaki je element ili nula ili je pripadna parcijalna derivacija nula (L1, odj. 3.1.1).

14. Multiplikativna pravila ažuriranja

Intuicija: odjeljak 5.

14.1 Izvod iz gradijentnog koraka

Gradijentni korak s duljinom koraka po elementu, $H \leftarrow H - \eta \odot \nabla_H f$, uz izbor $\eta = H \oslash \nabla_H^+ f$ daje

$$H - (H \oslash \nabla_H^+ f) \odot (\nabla_H^+ f - \nabla_H^- f) = H \odot \nabla_H^- f \oslash \nabla_H^+ f.$$

Uz gradijente iz propozicije 12.7 dobivamo pravila (L3, jedn. (4) i (5); L1, jedn. (5)):

$$\begin{aligned} &\text{KL:} && H \leftarrow H \odot [W^T(A \oslash WH)] \oslash [W^T\mathbf{1}], && W \leftarrow W \odot [(A \oslash WH)H^T] \oslash [\mathbf{1}H^T], \\ &\text{Frobenius:} && H \leftarrow H \odot (W^T A) \oslash (W^T WH), && W \leftarrow W \odot (AH^T) \oslash (WHH^T). \end{aligned}$$

Po elementima, za KL:

$$h_{kj} \leftarrow h_{kj} \frac{\sum_i w_{ik} a_{ij}/(WH)_{ij}}{\sum_i w_{ik}}.$$

Faktor je ponderirani prosjek omjera $a_{ij}/(WH)_{ij}$ s težinama $w_{ik}/\sum_l w_{lk}$. Veći je od 1 ako i samo ako je $\partial f/\partial h_{kj} < 0$ (usp. L1, odj. 3.1.2 za Frobeniusov slučaj).

Algoritam: KL-NMF s multiplikativnim pravilima

Ulaz: $A \geq 0$, rang r, početni $W^0 > 0$, $H^0 > 0$, tolerancija δ, najveći broj iteracija T.
Za $t = 0, 1, \ldots, T-1$:

1. $H \leftarrow H \odot [W^T(A \oslash WH)] \oslash [W^T\mathbf{1}]$;
2. $W \leftarrow W \odot [(A \oslash WH)H^T] \oslash [\mathbf{1}H^T]$ (s novim H);
3. normaliziraj stupce od W i prilagodi H (propozicija 12.3);
4. stani ako je $(f^t - f^{t+1})/f^t < \delta$.

14.2 Svojstva

Propozicija 14.1. *Neka je W bez nul-stupca i $f_{KL}(W,H) < \infty$, te neka je H^{nov} rezultat KL-pravila za H. Tada:*

(a) $H^{\text{nov}} \geq 0$, *a* $h_{kj} = 0$ *povlači* $h_{kj}^{\text{nov}} = 0$;

(b) *za* $h_{kj} > 0$ *vrijedi* $h_{kj}^{\text{nov}} = h_{kj}$ *ako i samo ako je* $\partial f_{KL}/\partial h_{kj} = 0$;

(c) (*vlastiti izvod*) $\sum_i (WH^{\text{nov}})_{ij} = \sum_i a_{ij}$ *za svaki* j.

Dokaz. (a) Svi su faktori nenegativni. (b) Iz $\nabla^- = \nabla^+ - \nabla$ slijedi $h_{kj}^{\text{nov}} = h_{kj}(1 - \partial_{kj} f/(W^T\mathbf{1})_{kj})$. (c) Uz $d_k = \sum_i w_{ik}$:

$$\sum_i (WH^{\text{nov}})_{ij} = \sum_k d_k h_{kj}^{\text{nov}} = \sum_k h_{kj} \sum_i \frac{w_{ik} a_{ij}}{(WH)_{ij}} = \sum_i a_{ij} \frac{\sum_k w_{ik} h_{kj}}{(WH)_{ij}} = \sum_i a_{ij},$$

pri čemu zbrajamo samo po i s $a_{ij} > 0$, za koje je $(WH)_{ij} > 0$. □

Napomena 14.2. Po (c), nakon svakog koraka za H model u svakom okviru ima ukupnu energiju jednaku izmjerenoj. Tada je $D(a_j \,\|\, Wh_j) = \sum_i a_{ij} \log \frac{a_{ij}}{(Wh_j)_i} = s_j \,\mathrm{KL}(p_j \| q_j)$, uz $s_j = \sum_i a_{ij}$, $p_j = a_j/s_j$ i $q_j = Wh_j/s_j$. To je prava Kullback–Leiblerova divergencija normiranih spektara, pomnožena glasnoćom okvira (usp. L3, odj. 3).

Primjer 14.3 (razrađene iteracije; vlastiti izvod). Neka je $W = \left(\begin{smallmatrix} 1 & 1 \\ 1 & 0 \end{smallmatrix}\right)$, $a = (2,1)^T$ i $h^0 = (1,\ 1/5)^T$. Rješenje je $h^* = W^{-1}a = (1,1)^T$ uz $D = 0$. Prvi korak: $Wh^0 = (6/5,\ 1)^T$, omjeri $a \oslash Wh^0 = (5/3,\ 1)^T$, $W^T(a \oslash Wh^0) = (8/3,\ 5/3)^T$, $W^T\mathbf{1} = (2,\ 1)^T$, pa je $h^1 = (4/3,\ 1/3)^T$. Dalje:

t	h_1^t	h_2^t	$(Wh^t)_1$	$(Wh^t)_2$	$D(a \,\|\, Wh^t)$
0	1	0,2	1,2	1	0,2217
1	1,3333	0,3333	1,6667	1,3333	0,0770
2	1,3	0,4	1,7	1,3	0,0627
3	1,2647	0,4706	1,7353	1,2647	0,0491

Od $t = 1$ je $\sum_i (Wh^t)_i = 3 = \sum_i a_i$, kako tvrdi propozicija 14.1(c). Numerička provjera pokazuje da se iterati približavaju $(1,1)$.

15. Monotonost: metoda pomoćne funkcije

Intuicija: odjeljak 5.

Definicija 15.1 (pomoćna funkcija; L3, definicija 1)**.** $G(h, \tilde{h})$ je pomoćna funkcija za F ako je $G(h,\tilde{h}) \geq F(h)$ za sve h i $G(\tilde{h},\tilde{h}) = F(\tilde{h})$.

Lema 15.2 (L3, lema 1)**.** *Ako je* G *pomoćna funkcija za* F *i* $G(h^{t+1}, h^t) \leq G(h^t, h^t)$*, posebno ako je* $h^{t+1} \in \arg\min_h G(h, h^t)$*, tada je* $F(h^{t+1}) \leq F(h^t)$.

Dokaz. $F(h^{t+1}) \leq G(h^{t+1}, h^t) \leq G(h^t, h^t) = F(h^t)$. □

Zbog rastava iz propozicije 12.6 dovoljno je promatrati jedan stupac. Neka je $a \in \mathbb{R}^m_{\geq 0}$, $W \in \mathbb{R}^{m\times r}_{\geq 0}$ bez nul-stupca, $d_k = \sum_i w_{ik} > 0$, $I_+ = \{i : a_i > 0\}$ i

$$F(h) = D(a \,\|\, Wh), \qquad \operatorname{dom} F = \{h \geq 0 : (Wh)_i > 0 \ \forall i \in I_+\}.$$

Lema 15.3 (Jensenova majoranta; L3, lema 3, s obradom nula)**.** *Neka je* $\tilde{h} \in \operatorname{dom} F$*. Za* $i \in I_+$ *neka je* $S_i = \{k : w_{ik}\tilde{h}_k > 0\}$ *i* $\lambda_{ik} = w_{ik}\tilde{h}_k/(W\tilde{h})_i$ *za* $k \in S_i$*. Definiramo*

$$G(h,\tilde{h}) = \sum_{i=1}^m (a_i \log a_i - a_i + (Wh)_i) - \sum_{i\in I_+} a_i \sum_{k\in S_i} \lambda_{ik} \log \frac{w_{ik} h_k}{\lambda_{ik}},$$

uz $a_i \log a_i = 0$ *za* $a_i = 0$ *i* $G = +\infty$ *ako je* $h_k = 0$ *za neki* $k \in S_i$*,* $i \in I_+$*. Tada je* G *pomoćna funkcija za* F *na* $\mathbb{R}^r_{\geq 0}$.

Dokaz. Skup S_i je neprazan jer je $(W\tilde{h})_i > 0$, a $\lambda_{ik} > 0$ i $\sum_{k\in S_i} \lambda_{ik} = 1$. Neka je $h \geq 0$ s $h_k > 0$ za sve $k \in S_i$ (inače je $G = \infty \geq F$). Ispuštanjem nenegativnih članova, a zatim Jensenovom nejednakošću za konkavni log, dobivamo

$$\log(Wh)_i \geq \log \sum_{k\in S_i} \lambda_{ik} \frac{w_{ik}h_k}{\lambda_{ik}} \geq \sum_{k\in S_i} \lambda_{ik} \log \frac{w_{ik}h_k}{\lambda_{ik}}.$$

Množenjem s $-a_i < 0$ i zbrajanjem po $i \in I_+$ dobivamo $F(h) \leq G(h, \tilde{h})$. Za $h = \tilde{h}$ je $w_{ik}\tilde{h}_k/\lambda_{ik} = (W\tilde{h})_i$ za svaki $k \in S_i$, pa se obje nejednakosti pretvaraju u jednakosti i $G(\tilde{h}, \tilde{h}) = F(\tilde{h})$. □

Teorem 15.4 (Lee i Seung; L3, teorem 2)**.** *Neka je $\tilde{h} \in \operatorname{dom} F$ i*

$$h_k^{\text{nov}} = \tilde{h}_k \frac{(W^T(a \oslash W\tilde{h}))_k}{d_k}, \qquad k = 1, \dots, r,$$

uz $a_i/(W\tilde{h})_i = 0$ za $a_i = 0$. Tada je h^{nov} minimum od $G(\cdot, \tilde{h})$ na $\mathbb{R}^r_{\geq 0}$, $h^{\text{nov}} \in \operatorname{dom} F$ i $F(h^{\text{nov}}) \leq F(\tilde{h})$.

Posljedično, ako W nema nul-stupac i $f_{KL}(W, H) < \infty$, KL-pravilo za H ne povećava f_{KL}. Ako H nema nul-redak, KL-pravilo za W ne povećava f_{KL}.

Dokaz. Do na članove koji ne ovise o h,

$$G(h, \tilde{h}) = \sum_{k=1}^{r} (d_k h_k - c_k \log h_k), \qquad c_k = \sum_{i\in I_+ : k\in S_i} a_i \lambda_{ik} = \tilde{h}_k \sum_{i\in I_+} \frac{w_{ik}a_i}{(W\tilde{h})_i} \geq 0.$$

(Za $k \notin S_i$ je $w_{ik}\tilde{h}_k = 0$, pa smijemo zbrajati po svim $i \in I_+$.) Funkcija se rastavlja po koordinatama. Ako je $c_k > 0$, funkcija $x \mapsto d_k x - c_k \log x$ strogo je konveksna na $(0, \infty)$, teži u $+\infty$ na oba kraja i ima minimum u $x = c_k/d_k$. Ako je $c_k = 0$, funkcija je $d_k x$ s minimumom na $[0, \infty)$ u $x = 0 = c_k/d_k$. U oba slučaja je minimum $c_k/d_k = h_k^{\text{nov}}$. Po lemi 15.2 je $F(h^{\text{nov}}) \leq F(\tilde{h}) < \infty$, pa je $h^{\text{nov}} \in \operatorname{dom} F$.

Za matrice: pravilo za H djeluje na svaki stupac upravo ovako, a f_{KL} je zbroj stupčanih članova, pa nijedan član ne raste. Pravilo za W je pravilo za H u transponiranom problemu $D(A^T \,\|\, H^T W^T)$; tamo ulogu od d_k preuzima $\sum_j h_{kj}$, pa H ne smije imati nul-redak. □

Teorem 15.5 (Lee i Seung; L3, teorem 1)**.** *Neka je $F(h) = \frac{1}{2}\|a - Wh\|^2$, $\tilde{h} > 0$ i $W^T W\tilde{h} > 0$. Tada $h^{\text{nov}} = \tilde{h} \odot (W^T a) \oslash (W^T W\tilde{h})$ zadovoljava $F(h^{\text{nov}}) \leq F(\tilde{h})$.*

Dokaz. Neka je $K = \operatorname{diag}((W^T W\tilde{h})_k/\tilde{h}_k)$ i $G(h, \tilde{h}) = F(\tilde{h}) + \nabla F(\tilde{h})^T(h - \tilde{h}) + \frac{1}{2}(h - \tilde{h})^T K(h - \tilde{h})$. Budući da je F kvadratna, $F(h) = F(\tilde{h}) + \nabla F(\tilde{h})^T(h - \tilde{h}) + \frac{1}{2}(h - \tilde{h})^T W^T W(h - \tilde{h})$, pa je $G - F = \frac{1}{2}(h - \tilde{h})^T(K - W^T W)(h - \tilde{h})$. Pokažimo da je $K - W^T W$ pozitivno semidefinitna (L3, lema 2). Uz $M = \operatorname{diag}(\tilde{h})(K - W^T W)\operatorname{diag}(\tilde{h})$ i $Q = W^T W \geq 0$ je

$$\nu^T M \nu = \sum_{k,l} Q_{kl}\tilde{h}_k\tilde{h}_l(\nu_k^2 - \nu_k\nu_l) = \frac{1}{2}\sum_{k,l} Q_{kl}\tilde{h}_k\tilde{h}_l(\nu_k - \nu_l)^2 \geq 0,$$

a $\operatorname{diag}(\tilde{h})$ je invertibilna. Dakle G je pomoćna funkcija. Njezin minimum je $h = \tilde{h} - K^{-1}\nabla F(\tilde{h}) = \tilde{h} - (\tilde{h} \oslash W^T W\tilde{h}) \odot (W^T W\tilde{h} - W^T a) = h^{\text{nov}}$, pa tvrdnja slijedi iz leme 15.2. □

Korolar 15.6. *Uz pretpostavke teorema 15.4 u svakom koraku niz $f_{KL}(W^t, H^t)$ je nerastući i omeđen odozdo nulom, pa konvergira. To ne govori ništa o konvergenciji samih iterata (W^t, H^t).*

16. Što jest, a što nije dokazano o konvergenciji

Intuicija: odjeljak 6.

Propozicija 16.1 (pozitivna granica je stacionarna; argument iz L4, odj. 3.1, prenesen na KL)**.** *Neka je Φ KL-pravilo iz teorema 15.4, $h^{t+1} = \Phi(h^t)$ i $h^t \to h^* \in \operatorname{dom} F$. Tada je $\Phi(h^*) = h^*$ i za svaki k s $h^*_k > 0$ vrijedi $\partial_k F(h^*) = 0$.*

Dokaz. Φ je neprekidna na otvorenom skupu $\{h : (Wh)_i > 0\ \forall i \in I_+\}$ koji sadrži h^*, pa je $h^* = \lim \Phi(h^t) = \Phi(h^*)$. Kao u propoziciji 14.1(b), $\Phi_k(h) = h_k(1 - \partial_k F(h)/d_k)$, pa iz $h^*_k > 0$ slijedi $\partial_k F(h^*) = 0$. □

Za $h^*_k = 0$ stacionarnost bi tražila $\partial_k F(h^*) \geq 0$, a to ne mora vrijediti:

Primjer 16.2 (nepomična točka koja nije stacionarna; vlastiti izvod)*.* Uz W i a iz primjera 14.3 i $h^0 = (1,0)^T$ je $Wh^0 = (1,1)^T$, $W^T(a \oslash Wh^0) = (3,2)^T$, pa je $h^1 = (3/2,\ 0)^T$, i dalje $h^t = h^1$ za sve $t \geq 1$. Pritom je $D = \log(32/27) \approx 0{,}170 > 0 = \min D$ i

$$\partial_2 F(h^1) = w_{12}\Big(1 - \frac{a_1}{(Wh^1)_1}\Big) + w_{22}\Big(1 - \frac{a_2}{(Wh^1)_2}\Big) = 1 - \tfrac{4}{3} = -\tfrac{1}{3} < 0.$$

Točka je nepomična, ali nije stacionarna, jer bi povećanje h_2 smanjilo D. Tvrdnja iz L3 uz teorem 2 da je divergencija nepromijenjena „ako i samo ako“ su W i H u stacionarnoj točki stoga ne vrijedi na rubu dopustivog skupa. Primjer je za korak samo po H uz fiksiran W, što je upravo situacija pri transkripciji.

Napomena 16.3 (što kaže literatura)*.* L3 nakon leme 1 tvrdi da iteriranje vodi do lokalnog minimuma. L4 (odj. 3.1) navodi da je ta tvrdnja kasnije opovrgnuta: dokaz daje samo nerast, koji ne isključuje sedlo. Granična točka u unutrašnjosti je stacionarna, a za rubnu točku to se ne može zaključiti. L4 to izvodi za Frobeniusovu verziju; propozicija 16.1 isti argument prenosi na KL. L1 (odj. 3.1.2) opisuje isto ograničenje i popravke: modificirano pravilo s jamstvom konvergencije prema stacionarnoj točki (Lin [Lin]), ponovno postavljanje nula na mali pozitivan broj kad im je derivacija negativna (Chi i Kolda [CK]) te donju granicu ε za elemente. Te popravke ovdje ne dokazujemo.

Napomena 16.4 (potproblem uz fiksiran W)*.* Pri transkripciji rješavamo samo konveksan problem po H. Teorem 15.4 daje nerast, a teorem 13.2 kaže da je svaka točka koja zadovoljava uvjete optimalnosti globalni minimum. Ovdje ne dokazujemo da iterati iz pozitivne početne točke konvergiraju globalnom minimumu. Isto pravilo poznato je kao Richardson–Lucyjev algoritam, odnosno EM algoritam za Poissonov model u emisijskoj tomografiji (Shepp i Vardi [SV]), gdje postoje rezultati o konvergenciji. Nisu u našoj literaturi i treba ih provjeriti prije citiranja. U praksi na kraju numerički provjeravamo uvjete optimalnosti i prijavljujemo koliko odstupaju.

17. Praktični detalji algoritma

Inicijalizacija (L1, odj. 3.1.8)**.** Pozitivni slučajni brojevi uz zabilježeno sjeme, i nekoliko pokretanja. Nula u inicijalizaciji ostaje nula zauvijek (propozicija 14.1(a)), a $(0,0)$ je stacionarna točka (primjer 13.5), pa nule stavljamo samo namjerno.

Normalizacija. Nakon koraka za W normaliziramo stupce od W i prilagodimo H (propozicija 12.3). Funkcija cilja se ne mijenja, pa monotonost ostaje očuvana, a h_{kj} dobiva značenje mase komponente k u okviru j.

Numerička zaštita. Dijeljenje s nulom javlja se kad je $(WH)_{ij} = 0$, kad W ima nul-stupac ili H nul-redak. Uobičajeno je nazivnicima dodati mali $\varepsilon > 0$; L4 u primjeru koda koristi 10^{-9}. To mijenja algoritam: teorem 15.4 vrijedi za točno pravilo. Svaku zaštitu imenujemo, opisujemo u izvodu i testiramo, kako traži pravilo 2.4 repozitorija.

Zaustavljanje (L1, odj. 3.1.7). Koristimo relativno smanjenje $(f^t - f^{t+1})/f^t < \delta$ i najveći broj iteracija T. Zbog propozicije 11.4 relativni kriterij za KL ne ovisi o ukupnoj glasnoći snimke. Ograničenje T je nužno: ako $f^t \to 0$ geometrijski, relativno smanjenje ne mora pasti ispod δ. Kriterij temeljen na uvjetima optimalnosti osjetljiv je na skaliranje (L1, jedn. (8) i rasprava uz nju).

Složenost. Jedan korak za H traži WH ($O(mnr)$), $A \oslash WH$ ($O(mn)$), množenje s W^T ($O(mnr)$) i $W^T\mathbf{1}$ ($O(mr)$); korak za W je analogan. Ukupno $O(mnr)$ operacija po iteraciji i $O(mn)$ memorije.

18. Primjena: učenje, transkripcija i vrednovanje

Intuicija: odjeljak 7.

18.1 Matrica za učenje i maskirani NMF

Spektrograme snimaka za učenje spojimo po stupcima, $A = [A^{(1)} \ \cdots \ A^{(S)}]$. Matrica W je zajednička, a H ima po jedan blok stupaca za svaku snimku. Iz oznaka gradimo masku $M \in \{0,1\}^{r\times n}$, gdje je $M_{kj} = 1$ ako nota k zvuči u okviru j. Problem je

$$\min \ D(A \,\|\, WH) \quad \text{uz} \quad W \geq 0,\ H \geq 0,\ h_{kj} = 0 \text{ za } M_{kj} = 0.$$

Propozicija 18.1 (maskirano učenje; vlastiti izvod)**.** *Neka je $W^0 > 0$, $h^0_{kj} > 0$ točno za $M_{kj} = 1$ i neka svaki stupac $a_j \neq 0$ ima barem jednu aktivnu komponentu. Tada iterati KL-pravila zadovoljavaju ograničenja maske i $f_{KL}(W^0, H^0) < \infty$. Sve dok W nema nul-stupac i H nema nul-redak, nijedan korak ne povećava f_{KL}.*

Dokaz. Nule ostaju nule (propozicija 14.1(a)), pa se maska čuva. Početna vrijednost je konačna jer je za $a_j \neq 0$ barem jedan $h^0_{kj} > 0$, a $W^0 > 0$. Teorem 15.4 ne traži pozitivnost od $\tilde{h}$, nego samo $\tilde{h} \in \operatorname{dom} F$; korak po H traži da W nema nul-stupac, a korak po W da H nema nul-redak. □

Napomena 18.2. Notu čiji redak u M nema nijednu jedinicu (ne pojavljuje se u skupu za učenje) treba izbaciti, jer bi H od početka imao nul-redak. Uvjet za stupce narušava okvir bez ijedne note u kojem ima šuma. Tada dodajemo komponentu k_0 s $M_{k_0 j} = 1$ za sve j, koja uči spektar pozadine, ili takve okvire izbacimo. Ako tijekom iteracija neki redak od H ili stupac od W padne na nulu, treba zaštita iz odjeljka 17. Jednostavnija alternativa maskiranom NMF-u je predložak kao prosjek normaliziranih stupaca a_j u kojima svira samo nota k.

18.2 Transkripcija

Za testnu snimku sa spektrogramom A' i fiksiranim naučenim W (normaliziranih stupaca) rješavamo $\min_{H\geq 0} D(A' \,\|\, WH)$. Problem je konveksan i rastavlja se po okvirima (propozicija 12.6). Rješavamo ga KL-pravilom samo za H iz $H^0 > 0$. Zatim:

1. $\hat{P}_{kj} = 1$ ako je $h_{kj} \geq \theta \max_{k',j'} h_{k'j'}$, inače 0;
2. maksimalni nizovi uzastopnih jedinica u retku k postaju note $(p_k, t_{\text{poč}}, t_{\text{kraj}})$, uz vremena okvira iz definicije 10.3;
3. note kraće od $d_{\min}$ odbacujemo.

Sve hiperparametre (N, L, θ, $d_{\min}$, broj predložaka po visini, δ, T) biramo samo na gitaristima za učenje unutar svake podjele (pravilo 2.7 repozitorija).

18.3 Mjere uspjeha

Definicija 18.3 (mjere na razini nota)**.** Neka je $\mathcal{R}$ skup stvarnih, a $\mathcal{E}$ skup procijenjenih nota. Par $(e, \rho) \in \mathcal{E} \times \mathcal{R}$ je dopušten ako se visine razlikuju za najviše 50 centi i početci za najviše $\Delta_{\text{poč}}$ (uobičajeno 50 ms). Neka je TP najveći broj dopuštenih parova u kojima se svaka nota pojavljuje najviše jednom (najveće sparivanje u bipartitnom grafu). Tada

$$P = \frac{\mathrm{TP}}{|\mathcal{E}|}, \qquad R = \frac{\mathrm{TP}}{|\mathcal{R}|}, \qquad F_1 = \frac{2PR}{P + R}.$$

Napomena 18.4. Postoji i stroža inačica koja traži i blizak kraj note te mjera na razini okvira koja uspoređuje matrice $\hat{P}$ i stvarnu klavirsku rolu element po element. Tolerancije treba navesti uz rezultat; standardnu implementaciju ima biblioteka mir_eval [ME], čije zadane vrijednosti treba provjeriti. Ako je $\mathcal{E} = \emptyset$, preciznost nije definirana i to treba posebno prijaviti.

18.4 Plan vrednovanja

Za svakog gitarista $g = 1, \dots, 6$: naučimo W_g i odaberemo hiperparametre na ostalih pet, izmjerimo F_1 na gitaristu g. Prijavljujemo svih šest vrijednosti, njihov prosjek i standardnu devijaciju. Referentne metode (isti postupak s f_F i odabir spektralnih vrhova uz $p = 69 + 12\log_2(f/440)$) koriste iste podjele, pa ih uspoređujemo po gitaristu. Uz svako pokretanje bilježimo podatke, postavke, sjeme i reviziju koda (pravilo 2.6 repozitorija).

A. Karta literature

Tema	Izvor i mjesto	U skripti
Motivacija, aditivni dijelovi	L2; L1, odj. 2	odj. 3
Generalizirana KL divergencija	L3, odj. 3, jedn. (3)	def. u odj. 11
Poissonova izglednost	L2, jedn. (2)	prop. 11.6
Nejedinstvenost, NP-težina, rang	L1, odj. 3 (uvod)	odj. 12
Konveksni potproblemi	L3, odj. 3; L1, odj. 3.1	prop. 12.6
Uvjeti optimalnosti	L1, odj. 3.1.1; L4, odj. 3.1	odj. 13
Multiplikativna pravila	L3, odj. 4–5; L1, odj. 3.1.2	odj. 14
Dokaz nerasta	L3, odj. 6 (lema 1–3, teoremi 1–2)	odj. 15
Granice tvrdnji o konvergenciji	L4, odj. 3.1 i 3.4; L1, odj. 3.1.2	odj. 16
Zaustavljanje, inicijalizacija	L1, odj. 3.1.7 i 3.1.8	odj. 17
Glazba i NMF	L1, odj. 2 (uvod); [FBD]; [SB]	odj. 4
STFT	udžbenik obrade signala (odabrati)	odj. 10
Podaci i mjere	[GS]; [ME]	odj. 18

L5 i L6 (klasteriranje dokumenata, hijerarhijski NMF ranga 2) za ovu temu nisu potrebni.

B. Pitanja za obranu

1. Što su retci i stupci matrice A i zašto su njezini elementi nenegativni? (odj. 2, def. 10.3)
2. Zašto je spektar akorda samo približno zbroj spektara nota? Kada je točno zbroj? (prop. 10.6)
3. Kako izgleda predložak jedne note i zašto se oktave teško razlikuju? (slika 1)
4. Kako duljina prozora utječe na razlučivost u frekvenciji i vremenu? (odj. 2)
5. Zašto ne koristimo skraćeni SVD? (odj. 3)
6. Definirajte generaliziranu KL divergenciju i dokažite da je nenegativna. (prop. 11.3)
7. Zašto KL umjesto Frobeniusove norme? Koja je statistička interpretacija obiju? (prop. 11.4, 11.6)
8. Zašto NMF nije jedinstven i kako to rješavamo? (prop. 12.1, 12.3)
9. Pokažite da puni problem nije konveksan, a potproblem po H jest. (primjer 12.4, prop. 12.6)
10. Izvedite gradijent od $D(A \,\|\, WH)$ po H. (prop. 12.7)
11. Iskažite i dokažite uvjete optimalnosti na nenegativnom ortantu. (tm. 13.1)
12. Je li stacionarna točka nužno lokalni minimum? (primjer 13.5)
13. Izvedite multiplikativno pravilo iz gradijentnog koraka. Zašto čuva nenegativnost? (odj. 14)
14. Što je pomoćna funkcija i zašto osigurava nerast? (lema 15.2)
15. Dokažite teorem Leeja i Seunga za KL divergenciju. (lema 15.3, tm. 15.4)
16. Što točno znamo o konvergenciji multiplikativnih pravila? (odj. 16)
17. Može li algoritam zapeti u točki koja nije stacionarna? (primjer 16.2)
18. Zašto je obrada nove snimke uz fiksiran W lakša od učenja? (napomena 16.4)
19. Kako se uče predlošci i zašto maskiranje radi? (prop. 18.1)
20. Kako se iz H dobivaju note i kako biramo prag? (odj. 18)
21. Definirajte preciznost, odziv i F_1 na razini nota. Zašto provjera po gitaristu? (odj. 18)
22. Koje su glavne slabosti metode i kako bismo ih prijavili? (odj. 7)

Literatura

[L1] N. Gillis, *The Why and How of Nonnegative Matrix Factorization*, arXiv:1401.5226v2, 2014.

[L2] D. D. Lee, H. S. Seung, *Learning the parts of objects by non-negative matrix factorization*, Nature, 1999.

[L3] D. D. Lee, H. S. Seung, *Algorithms for Non-negative Matrix Factorization*.

[L4] M. W. Berry, M. Browne, A. N. Langville, V. P. Pauca, R. J. Plemmons, *Algorithms and Applications for Approximate Nonnegative Matrix Factorization*, radna verzija od 9. lipnja 2006.

Izvan priložene literature (pročitati i provjeriti prije citiranja): [FBD] C. Févotte, N. Bertin, J.-L. Durrieu, *Nonnegative matrix factorization with the Itakura-Saito divergence: With application to music analysis*, Neural Computation 21(3), 2009 (prema L1, ref. [42]). [SB] P. Smaragdis, J. C. Brown, *Non-negative matrix factorization for polyphonic music transcription*, IEEE WASPAA, 2003. [GS] Q. Xi i sur., *GuitarSet: A Dataset for Guitar Transcription*, ISMIR 2018. [ME] C. Raffel i sur., *mir_eval: A Transparent Implementation of Common MIR Metrics*, ISMIR 2014. [Lin] C.-J. Lin, *On the convergence of multiplicative update algorithms for nonnegative matrix factorization*, IEEE Trans. Neural Networks 18(6), 2007 (prema L1, ref. [87]). [CK] E. Chi, T. Kolda, *On tensors, sparsity, and nonnegative factorizations*, SIAM J. Matrix Anal. Appl. 33(4), 2012 (prema

L1, ref. [23]). [Vav] S. Vavasis, *On the complexity of nonnegative matrix factorization*, SIAM J. Optim. 20(3), 2009 (prema L1, ref. [105]). [SV] L. A. Shepp, Y. Vardi, *Maximum likelihood reconstruction for emission tomography*, IEEE Trans. Medical Imaging, 1982.